Modelos Visión-Lenguaje (VLMs)

Large vision-language models

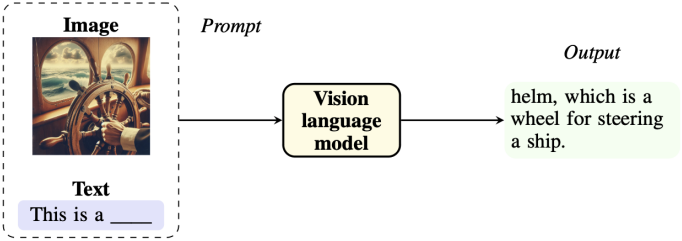
Juan Irving Vásquez[1]

[1]Centro de Innovación y Desarrollo Tecnológico en Cómputo
Instituto Politécnico Nacional

November 11, 2026



¿Qué son los Modelos Visión-Lenguaje?



- Los **Modelos Visión-Lenguaje (VLMs)** combinan la visión por computadora y el procesamiento de lenguaje natural (NLP) en un solo sistema multimodal.
- Integran un *codificador visual* y un *modelo de lenguaje grande (LLM)*, permitiendo razonar sobre imágenes, videos y texto simultáneamente.
- Ejemplos de tareas: generar subtítulos de imágenes, responder preguntas visuales o buscar imágenes mediante descripciones textuales.

Esquema general

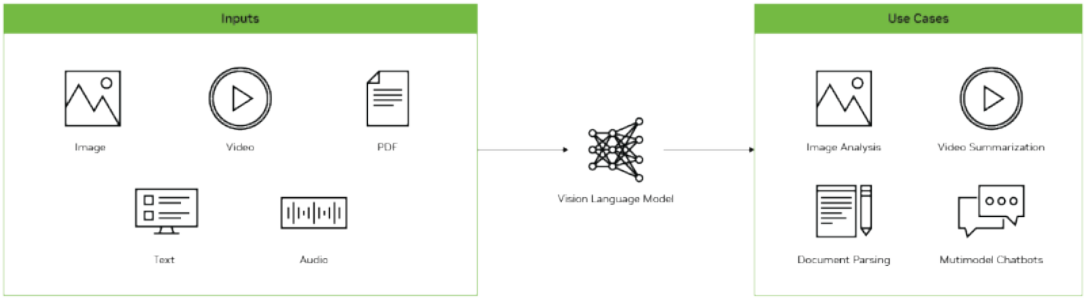


Figure: Ejemplo de flujo multimodal entre visión y lenguaje.

Importancia de los VLMs

- Superan las limitaciones de los modelos tradicionales de visión, al no restringirse a un conjunto fijo de clases o tareas.
- Gracias a su entrenamiento en grandes colecciones de pares imagen-texto, pueden aprender instrucciones en lenguaje natural y adaptarse a nuevas tareas.
- Habilitan aplicaciones de **IA generativa multimodal**, integrando texto, imagen, audio y video.

Arquitectura de los VLMs

- Tres bloques principales:
  1. **Codificador de visión:** transforma imágenes o video en embeddings.
  2. **Fusor o proyector:** alinea los espacios de visión y lenguaje en un mismo dominio semántico.
  3. **Modelo de lenguaje grande (LLM):** interpreta o genera texto a partir de la información visual.
- Generalmente se basan en arquitecturas tipo *Transformers*, como **CLIP** o **ViT**.
- La integración de estos módulos permite razonar de forma multimodal y generar respuestas contextuales.

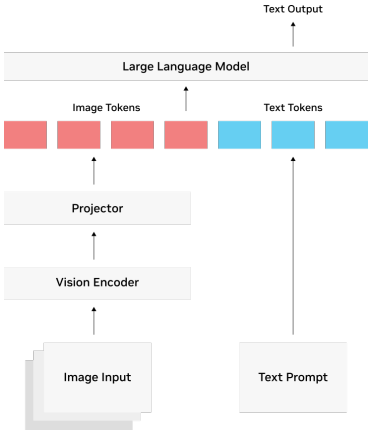
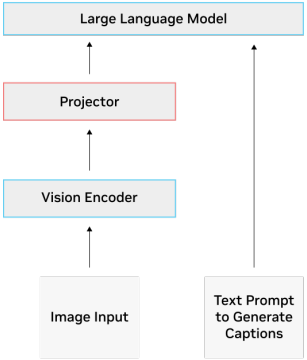


Figure: Arquitectura típica de un modelo Visión-Lenguaje.

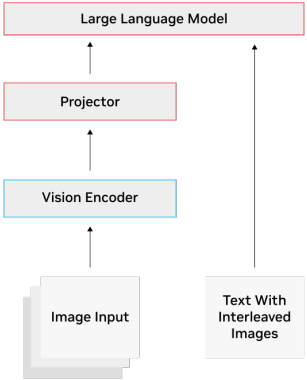
Entrenamiento de los VLMs

- Los VLMs se entrenan mediante diversas estrategias:
  1. **Aprendizaje contrastivo:** alinea embeddings de imagen y texto (ej. CLIP).
  2. **Enmascaramiento:** predice partes ocultas en texto o imagen.
  3. **Entrenamiento generativo:** produce texto desde imágenes o viceversa.
- Generalmente combinan modelos preentrenados de visión y lenguaje antes de un ajuste fino (*fine-tuning*) en datos multimodales específicos.

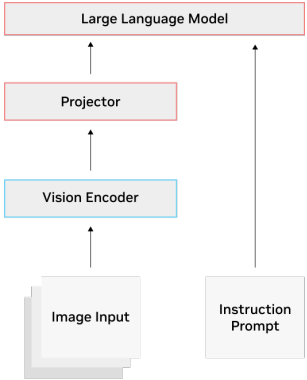
Diagrama del Proceso de Entrenamiento



Stage 1: Projector Initialization
Trained on image caption pairs



Stage 2: Visual-Language Pre-Training
Trained on interleaved image-text and image-text pairs



Stage 3: Visual Instruction Tuning
Trained on visual language instructions

The layers of the VLM that are updated during the training stage

The layers of the VLM that are not updated during the training stage

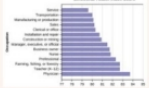
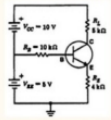
Modelos Representativos

- **CLIP (OpenAI):** pionero en aprendizaje contrastivo imagen-texto.
- **GPT-4o (OpenAI):** modelo multimodal capaz de procesar texto, imagen y audio.
- **Gemini 2.0 Flash (Google):** integración completa entre texto, imagen, audio y video.
- **Llama 3.2 (Meta):** modelo abierto con entrada de visión y texto.
- **NVLM (NVIDIA)** y **Qwen 2.5-VL (Alibaba)**: especializados en imágenes de alta resolución y video de larga duración.

Evaluación de VLMs

- Se evalúan mediante pruebas multimodales que miden razonamiento, comprensión visual y precisión textual:
  1. **MMBench, MMMU, MM-Vet**: razonamiento general.
  2. **OCRBench, MathVista**: comprensión de texto y símbolos en imágenes.
  3. **VQA**: respuestas a preguntas visuales.
- La evaluación busca medir tanto la precisión como la capacidad de generalización y razonamiento multimodal.

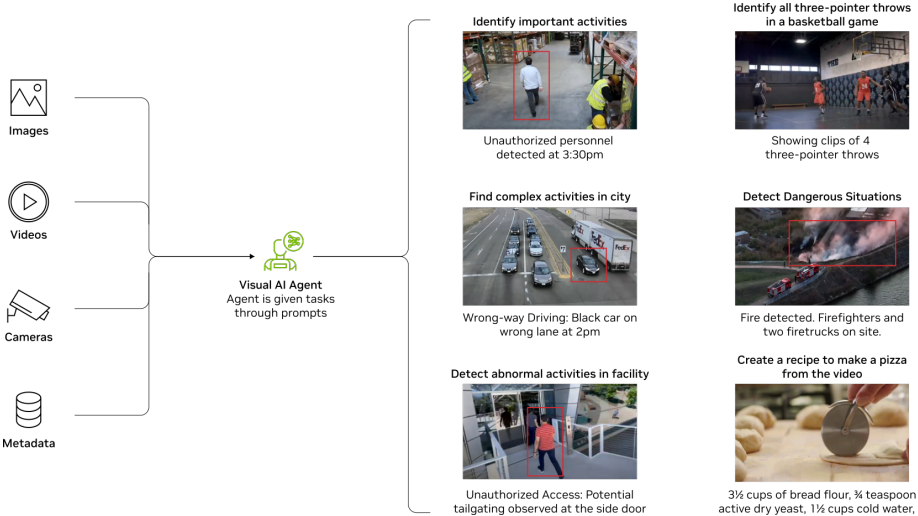
Ejemplo de evaluación

Art & Design	Business	Science
Question: Among the following harmonic intervals, which one is constructed incorrectly? **Options:** (A) Major third <*image 1*> (B) Diminished fifth <*image 2*> **(C) Minor seventh <*image 3*>** (D) Diminished sixth <*image 4*> 	**Question:** ...The graph shown is compiled from data collected by Gallup <*image 1*>. Find the probability that the selected Emotional Health Index Score is between 80.5 and 82? **Options:** (A) 0 (B) 0.2142 **(C) 0.3571** (D) 0.5 	**Question:** <*image 1*> The region bounded by the graph as shown above. Choose an integral expression that can be used to find the area of R. **Options:** **(A)** $\int_0^{1.5}[f(x)-g(x)]dx$ (B) $\int_0^{1.5}[g(x)-f(x)]dx$ (C) $\int_0^{2}[f(x)-g(x)]dx$ (D) $\int_0^{2}[g(x)-x(x)]dx$ 
Subject: Music; **Subfield:** Music; **Image Type:** Sheet Music; **Difficulty:** Medium	**Subject:** Marketing; **Subfield:** Market Research; **Image Type:** Plots and Charts; **Difficulty:** Medium	**Subject:** Math; **Subfield:** Calculus; **Image Type:** Mathematical Notations; **Difficulty:** Easy
Health & Medicine	**Humanities & Social Science**	**Tech & Engineering**
Question: You are shown subtraction <*image 1*>, T2 weighted <*image 2*> and T1 weighted axial <*image 3*> from a screening breast MRI. What is the etiology of the finding in the left breast? **Options:** (A) Susceptibility artifact (B) Hematoma **(C) Fat necrosis** (D) Silicone granuloma 	**Question:** In the political cartoon, the United States is seen as fulfilling which of the following roles? <*image 1*> **Option**: (A) Oppressor (B) Imperialist **(C) Savior** (D) Isolationist 	**Question:** Find the VCE for the circuit shown in <*image 1*>. Neglect VBE **Answer: 3.75** **Explanation**: ...IE = [(VEE) / (RE)] = [(5 V) / (4 k-ohm)] = 1.25 mA; VCE = VCC - IERL = 10 V - (1.25 mA) 5 k-ohm; VCE = 10 V - 6.25 V = 3.75 V 
Subject: Clinical Medicine; **Subfield:** Clinical Radiology; **Image Type:** Body Scans: MRI, CT.; **Difficulty:** Hard	**Subject:** History; **Subfield:** Modern History; **Image Type:** Comics and Cartoons; **Difficulty:** Easy	**Subject:** Electronics; **Subfield:** Analog electronics; **Image Type:** Diagrams; **Difficulty:** Hard

Aplicaciones de los VLMs

- **Generación de descripciones** de imágenes o videos.
- **Búsqueda visual semántica**: encontrar imágenes a partir de texto.
- **Segmentación y detección de objetos** con explicación textual.
- **Respuesta a preguntas visuales (VQA)**.
- **Diseño asistido y generación de imágenes** (text-to-image).
- Usos en medicina, robótica, educación, arte y sistemas de monitoreo ambiental.

Aplicaciones en el mundo real



Desafíos y Riesgos

- **Sesgos de datos:** los modelos pueden reflejar prejuicios presentes en los conjuntos de entrenamiento.
- **Costos computacionales elevados** para entrenamiento y despliegue.
- **Generalización limitada** en escenarios no vistos o de dominio distinto.
- **Alucinaciones**: generación de descripciones falsas o incorrectas.
- **Gobernanza y ética**: necesidad de regulación, validación y control humano.

Conclusiones

- Los VLMs integran comprensión visual y lingüística en un solo sistema, habilitando una nueva generación de aplicaciones multimodales.
- Representan un paso hacia **IA generalista**, capaz de razonar sobre múltiples modalidades.
- Su futuro depende de avances en alineación, ética, eficiencia y robustez.

Referencias

- IBM Think (2025). *What are Vision-Language Models?* Disponible en: https://www.ibm.com/think/topics/vision-language-models
- NVIDIA Glossary (2024). *What are Vision-Language Models?* https://www.nvidia.com/en-us/glossary/vision-language-models/